

Data Mining

Dr. Sirojul Munir S.Si., M.Kom

STT Terpadu Nurul Fikri





Algoritma Regresi


Dr. Sirojul Munir S.Si.,M.Kom | rojulman@nurulfikri.ac.id



   @rojulman



DATA MINING



Data sets



Pre-processing



Classification



Database



Statistics




Analytics



Evaluation

Algoritma *Regression*

- Memprediksi nilai numerik berdasarkan inputan data
- Algoritma **memodelkan hubungan** antara satu atau lebih **variabel bebas** (independen) dengan **variabel target** (dependen) yang bersifat kontinu.
- Tujuan: memprediksi nilai variabel dependen (y) berdasarkan variabel independen (x)




$$y = b * x + c$$

Diagram illustrating the components of the regression equation $y = b * x + c$:

- y : value of the estimated dependent variable
- b : regression coefficient
- x : value of the independent variable
- c : constant

Regression Algorithm

The goal of regression is to find a **mathematical relationship** between the **input features** and the **target variable** that can be used to make **accurate predictions** on new, unseen data



@arunp77

Algoritma *Regression*



Stock Market Prediction





Figure 7. Line graph RFR model prediction: Origin vs. Estimated Values, with data sorted by the origin value of increasing order in the x axis.





Prediksi Data Deret Waktu

Dr. Sirojul Munir S.Si.,M.Kom | rojulman@nurulfikri.ac.id



   @rojulman

Time Series Dataset

Apa itu Data Time Series?

Data time series adalah serangkaian pengamatan yang dikumpulkan secara berurutan dalam interval waktu yang teratur.

Komponen Utama:

Trend	Seasonality	Cyclicalitiy	Irregularity
Pola jangka panjang naik atau turun	Pola yang berulang dalam periode tertentu	Fluktuasi jangka panjang tanpa periode tetap	Variasi acak atau noise yang tidak terduga

Time Series (Deret Waktu)


- **Deret waktu** adalah kumpulan titik data berurutan, yang biasanya diukur pada **periode waktu yang berurutan**
- **Deret waktu** yang berisi nilai dari satu variabel **tunggal** disebut **univariat**.
Namun, jika nilai dari **lebih dari satu variabel** dipertimbangkan, maka disebut **multivariat**.



Time Series (Deret Waktu)



- ***Time series*** dapat berupa data **kontinu** atau **diskrit**
- **Kontinu**: Data pengamatan diukur pada **setiap waktu** (kontinu)
- Contoh: sensor suhu / temperature, sinyal EKG, gelombang seismik gempa bumi, sinyal audio / suara, monitoring tekanan darah



Time Series (Deret Waktu)



- ***Time series*** dapat berupa data **kontinu** atau **diskrit**
- **Diskrit:** Data pengamatan diukur pada **titik waktu yang diskrit**
- Contoh: populasi penduduk, produksi dari pabrik, nilai tukar rupiah, harga saham, arus lalu lintas




Time Series Dataset

Yahoo Stock


	Date	High	Low	Open	Close	Volume	Adj Close
0	2015-11-23	2095.610107	2081.389893	2089.409912	2086.590088	3.587980e+09	2086.590088
1	2015-11-24	2094.120117	2070.290039	2084.419922	2089.139893	3.884930e+09	2089.139893
2	2015-11-25	2093.000000	2086.300049	2089.300049	2088.870117	2.852940e+09	2088.870117
3	2015-11-26	2093.000000	2086.300049	2089.300049	2088.870117	2.852940e+09	2088.870117
4	2015-11-27	2093.290039	2084.129883	2088.820068	2090.110107	1.466840e+09	2090.110107
5	2015-11-28	2093.290039	2084.129883	2088.820068	2090.110107	1.466840e+09	2090.110107
6	2015-11-29	2093.290039	2084.129883	2088.820068	2090.110107	1.466840e+09	2090.110107
7	2015-11-30	2093.810059	2080.409912	2090.949951	2080.409912	4.275030e+09	2080.409912
8	2015-12-01	2103.370117	2082.929932	2082.929932	2102.629883	3.712120e+09	2102.629883
9	2015-12-02	2104.270020	2077.110107	2101.709961	2079.510010	3.950640e+09	2079.510010



Time Series (Deret Waktu)



Time Series (Deret Waktu)



Gambar 6. Prediksi produksi kelapa sawit pada data valid

Algoritma Time Series

1. Metode Statistik Klasik

Algoritma	Keterangan
ARIMA	Univariat, untuk data stasioner dengan differencing
SARIMA	ARIMA + komponen musiman (seasonal)
ARIMAX	ARIMA + variabel eksogen (multivariat)
Exponential Smoothing (ETS)	Pembobotan data historis, cocok untuk trend & seasonality
VAR	Vector Autoregression, multivariat
ARCH/GARCH	Khusus untuk volatilitas (populer di data keuangan/saham)



Algoritma Time Series

2. Machine Learning Klasik

Algoritma	Keterangan
SVR (Support Vector Regression)	Regresi berbasis SVM untuk pola non-linear
Random Forest	Ensemble decision tree, robust terhadap outlier
XGBoost / LightGBM	Gradient boosting, akurasi tinggi dengan fitur lag
KNN Regression	Prediksi berdasarkan kemiripan pola historis



Algoritma Time Series

3. Deep Learning

Algoritma	Keterangan
RNN	Recurrent Neural Network, menangkap dependensi temporal
LSTM	Long Short-Term Memory, mengatasi vanishing gradient RNN
GRU	Gated Recurrent Unit, lebih ringan dari LSTM
CNN-LSTM	Kombinasi CNN untuk ekstraksi fitur + LSTM untuk sekuens
Transformer	Berbasis attention mechanism, sangat kuat untuk sekuens panjang
Temporal Fusion Transformer (TFT)	Transformer khusus time series multivariat




Algoritma Time Series

4. Model Khusus Time Series Modern

Algoritma	Keterangan
Prophet (Meta/Facebook)	Otomatis menangani trend, seasonality, dan hari libur
N-BEATS	Neural basis expansion, pure deep learning untuk time series
TimesNet	Model berbasis CNN 2D untuk pola temporal
PatchTST	Transformer berbasis patch untuk time series panjang



Model ARIMA



- ❖ Model AutoRegressive Integrated Moving Average (ARIMA) dikembangkan George E.P. Box dan Gwilym M. Jenkins (1976), sehingga ARIMA juga disebut metode deret waktu Box-Jenkins.
- ❖ Model Box-Jenkins terdiri dari Model Stasioner: Autoregressive (AR), Moving Average (MA), Autoregressive-Moving Average (ARMA), dan
- ❖ Model NonStasioner: Autoregressive Integrated Moving Average (ARIMA)

Konsep Dasar ARIMA

ARIMA = AutoRegressive Integrated Moving Average

AR(p)

AutoRegressive

Model menggunakan nilai-nilai sebelumnya (lag) sebagai prediktor.

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t$$

p = orde AR (jumlah lag)

I(d)

Integrated

Proses differencing untuk membuat data menjadi stasioner.

$$\Delta Y_t = Y_t - Y_{t-1} \quad (d=1)$$

$$\Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1} \quad (d=2)$$

d = orde differencing

MA(q)

Moving Average

Model menggunakan residual/error dari prediksi sebelumnya.

$$Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

q = orde MA (jumlah lag error)

Model ARIMA(p, d, q)

$$\phi_p(B)(1-B)^d Y_t = \theta_q(B) \varepsilon_t$$

p

Jumlah lag pada komponen Autoregressive (AR)

Biasanya 0–3

d

Jumlah kali differencing agar data stasioner

Biasanya 0, 1, atau 2

q

Jumlah lag pada komponen Moving Average (MA)

Biasanya 0–3

Keterangan

B = Backshift operator

$$BY_t = Y_{t-1}$$

ε_t = White noise error

ϕ , θ = Parameter model

Tahapan Pemodelan ARIMA

1

Uji Stasioneritas

Uji ADF / KPSS. Jika tidak stasioner, lakukan differencing (d).

2

Identifikasi p & q

Plot ACF → tentukan q (MA). Plot PACF → tentukan p (AR).

3

Estimasi Parameter

Metode MLE / OLS untuk mengestimasi nilai ϕ dan θ .

4

Uji Diagnostik

Uji residual (Ljung-Box), normalitas, dan homoskedastisitas.


5

Peramalan (Forecast)

Hasilkan prediksi beserta confidence interval.


Identifikasi Model: ACF & PACF

Autocorrelation Function (ACF)



→ Pola menurun perlahan: indikasi data tidak stasioner atau ada komponen MA

Partial Autocorrelation Function (PACF)



→ Cut-off setelah lag 2: indikasi AR(2), pilih $p=2$

Aturan: ACF cut-off → tentukan q (MA order) | PACF cut-off → tentukan p (AR order)

Studi Kasus Saham

Prediksi Harga Saham BBCA (Bank Central Asia)

Saham	Periode	Frekuensi	Variabel
BBCA.JK	Jan 2022 – Des 2023	Harian (trading days)	Harga Penutupan (Close)



Implementasi Python – ARIMA BBKA

```
import pandas as pd
import yfinance as yf
from statsmodels.tsa.arima.model import ARIMA

# 1. Ambil data saham
df = yf.download('BBKA.JK',
                 start=
                 '2022-01-01', end='2024-01-01')
data = df['Close']


# 2. Fit model ARIMA(2,1,2)
model = ARIMA(data, order=(2,1,2))
result = model.fit()

# 3. Forecast 30 hari ke depan
forecast = result.get_forecast(steps=30)
pred = forecast.predicted_mean
ci = forecast.conf_int()
```

Langkah Implementasi:

- 1 Import library (pandas, yfinance, statsmodels)
- 2 Unduh data harga saham dengan yfinance
- 3 Uji stasioneritas dengan ADF test
- 4 Tentukan p, d, q dari plot ACF/PACF
- 5 Fitting model ARIMA(p,d,q)
- 6 Evaluasi model (AIC, residual)
- 7 Generate forecast + confidence interval

Hasil Prediksi ARIMA(2,1,2) – Saham BBKA



Metrik Evaluasi Model:

MAE

142.3 Rp

Mean Absolute Error

RMSE

189.7 Rp

Root Mean Square Error

MAPE

1.52%

Mean Absolute Percentage Error

AIC

-1842

Akaike Info Criterion

MAPE 1.52% → Tingkat akurasi sangat baik (< 5%) untuk prediksi harga saham jangka pendek

Evaluasi & Kesimpulan

Kelebihan ARIMA

- ✓ Mampu menangkap autokorelasi temporal dalam data
- ✓ Interpretasi statistik yang jelas dan terukur
- ✓ Efektif untuk data time series linear yang stasioner
- ✓ Tersedia library siap pakai (statsmodels, R forecast)

Keterbatasan ARIMA

- ✗ Hanya untuk hubungan linear (tidak menangkap non-linearitas)
- ✗ Sensitif terhadap outlier dan perubahan struktural pasar
- ✗ Kurang efektif untuk prediksi jangka panjang
- ✗ Memerlukan data yang stasioner (pre-processing)

Kesimpulan

ARIMA(2,1,2) berhasil memprediksi harga saham BBCA dengan MAPE 1.52%. Model ARIMA terbukti efektif sebagai metode baseline untuk time series finansial. Pengembangan ke SARIMA atau GARCH dapat meningkatkan akurasi lebih lanjut.

Praktikum

Prediksi Harga Saham Yahoo

	Date	High	Low	Open	Close	Volume	Adj Close
0	2015-11-23	2095.610107	2081.389893	2089.409912	2086.590088	3.587980e+09	2086.590088
1	2015-11-24	2094.120117	2070.290039	2084.419922	2089.139893	3.884930e+09	2089.139893
2	2015-11-25	2093.000000	2086.300049	2089.300049	2088.870117	2.852940e+09	2088.870117
3	2015-11-26	2093.000000	2086.300049	2089.300049	2088.870117	2.852940e+09	2088.870117
4	2015-11-27	2093.290039	2084.129883	2088.820068	2090.110107	1.466840e+09	2090.110107
5	2015-11-28	2093.290039	2084.129883	2088.820068	2090.110107	1.466840e+09	2090.110107
6	2015-11-29	2093.290039	2084.129883	2088.820068	2090.110107	1.466840e+09	2090.110107
7	2015-11-30	2093.810059	2080.409912	2090.949951	2080.409912	4.275030e+09	2080.409912
8	2015-12-01	2103.370117	2082.929932	2082.929932	2102.629883	3.712120e+09	2102.629883
9	2015-12-02	2104.270020	2077.110107	2101.709961	2079.510010	3.950640e+09	2079.510010



Praktikum

Prediksi Harga Saham Yahoo

